GUION DE EXPOSICIÓN ORAL • REPARTO EQUITATIVO (6 INTEGRANTES)

Modelado y Presentación de Datos

Avance 1: Aprendizaje No Supervisado | Caso Hospital María Auxiliadora

Ciclo: 2026-II (Ciclo VI)
Tiempo Total: 12 - 15 Minutos (~2:15 min/persona)
Población: 97,546 Pacientes

1. **Drey (Diapositivas 01 y 02)** — Portada, Problema Clínico y Objetivos
2. **Diego (Diapositivas 03 y 04)** — Feature Engineering y EDA Univariado
3. **Steven (Diapositivas 05 y 06)** — EDA Multivariado y Calidad de Datos
4. **Daniel (Diapositivas 07 y 08)** — Estandarización y Selección de K Óptimo
5. **Rosa (Diapositivas 09 y 10)** — PCA 2D y 4 Arquetipos de Pacientes
6. **Brillite (Diapositivas 11 y 12)** — Conclusiones, Avance 2 y Cierre

DIAPOSITIVA 01 Portada e Introducción Institucional — Drey

EN PANTALLA
Título oficial, caso María Auxiliadora, nombres del equipo y ciclo académico 2026-II.

TIEMPO ASIGNADO
0:45 min | Tono: Seguro, formal y cordial.

GUION VERBAL (DREY SE PRESENTA AL INICIO):

"Buenas noches, profesor y compañeros. **Mi nombre es Drey**, *y el día de hoy nuestro equipo presenta el* **Avance 1 del proyecto de Modelado y Presentación de Datos**. *En esta investigación abordamos una problemática real y crítica en la salud pública de Lima Sur: la* **segmentación de pacientes del Hospital María Auxiliadora** *mediante algoritmos de aprendizaje no supervisado. A lo largo de la presentación demostraremos cómo transformamos más de 450,000 registros transaccionales en* **cuatro grupos estratégicos** *utilizando modelos como* **K-Means, PCA y Clustering Jerárquico** *para mitigar el ausentismo y optimizar los recursos hospitalarios."*

DIAPOSITIVA 02 Criterio 1: Contexto Hospitalario y Necesidad Analítica — Drey

EN PANTALLA
4 KPIs de dolor: 450k citas, 31.8% No-Show, 19.8 días de espera y carencia de segmentación.

TIEMPO ASIGNADO
1:15 min | Tono: Enérgico, enfatizando las cifras de impacto.

GUION VERBAL DE DREY:

"El Hospital María Auxiliadora soporta una demanda masiva en consulta externa; sin embargo, enfrenta dos cuellos de botella muy graves: primero, una **tasa de ausentismo del 31.8%**, *lo que implica que* **casi 1 de cada 3 citas se pierde**, *dejando horas médicas especializadas inutilizadas que nunca se recuperan. Segundo, una demora promedio de* **19.8 días entre la solicitud y la atención**, *con picos que alcanzan casi 3 meses. El origen del problema es una* **gestión homogénea e indiferenciada**: *el hospital programa citas bajo las mismas reglas para un paciente crónico complejo que para un chequeo de rutina. Por ello, nuestro objetivo cuantitativo es segmentar a* **97,546 pacientes únicos** *para personalizar la gestión de citas y reducir el abandono."*

Frase de Pase de Drey: "A continuación, **le paso la palabra a mi siguiente compañero** para continuar con la exposición."

DIAPOSITIVA 03 Criterio 2: Carga de Datos y Feature Engineering (RFM Clínico) — Diego

EN PANTALLA
Diagrama del pipeline transaccional a paciente y tabla de las 10 variables numéricas.

TIEMPO ASIGNADO
1:15 min | Tono: Técnico, destacando el cumplimiento de la rúbrica.

🎙️ **GUION VERBAL (DIEGO SE PRESENTA AL INICIO):**

"Buenas noches a todos, **mi nombre es Diego**. *Para cumplir rigurosamente con los requisitos de la rúbrica del curso, convertimos el registro transaccional de citas en una matriz consolidada a nivel de paciente individual, estructurando un* **RFM clínico**. *Analizamos a* **97,546 pacientes únicos**, *superando por casi diez veces el mínimo exigido de 10,000 registros. Construimos un vector de* **10 variables 100% numéricas continuas y ratios de comportamiento**: *edad, sexo, total de citas, gasto total, gasto promedio, días de espera promedio, tasa efectiva de asistencia y ratios de aseguramiento y adopción de teleconsulta."*

DIAPOSITIVA 04 Criterio 2: EDA Univariado (Distribución y Dispersión) — Diego

EN PANTALLA
Gráficos `eda_univariado_histogramas.png` y `eda_univariado_boxplots.png`.

TIEMPO ASIGNADO
1:15 min | Tono: Analítico y descriptivo.

🎙️ **GUION VERBAL DE DIEGO:**

"Al analizar el comportamiento univariado de estas variables encontramos hallazgos esenciales: la variable **edad muestra una clara distribución bimodal**, *con picos marcados en niños menores de 10 años y adultos mayores entre 60 y 75 años, registrando una mediana de 41 años. Por otro lado, variables operativas como los días de espera y el gasto total presentan una* **fuerte asimetría positiva con colas pesadas** *hacia la derecha. Se comprueba un* **efecto Pareto evidente**: *el 80% de los usuarios tiene una baja frecuencia de 1 o 2 consultas anuales, mientras que una fracción de pacientes crónicos acumula más de 30 citas, generando valores extremos que debemos tratar cuidadosamente."*

🗣️ **Frase de Pase de Diego:** "A continuación, **le paso la palabra a mi siguiente compañero**."

DIAPOSITIVA 05 Criterio 2: EDA Multivariado (Correlaciones y Dispersión) — Steven

EN PANTALLA
Heatmap triangular de Pearson (`eda_multivariado_heatmap.png`) y scatter plot bivariado.

TIEMPO ASIGNADO
1:15 min | Tono: Persuasivo, fundamentando la causa del abandono.

GUION VERBAL (STEVEN SE PRESENTA AL INICIO):

"Buenas noches, profesor y jurado, **mi nombre es Steven**. *Al explorar la matriz de correlación multivariada comprobamos dos relaciones determinantes: primero, una* **asociación lineal positiva muy fuerte (r = 0.85)** *entre el total de citas y el gasto acumulado, confirmando que la recurrencia médica tracciona directamente el costo del paciente. Segundo, y fundamental para la gestión: identificamos una* **correlación negativa entre los días de espera y la tasa de asistencia**. *Esto demuestra cuantitativamente que* **a mayor tiempo de espera programado, mayor es el riesgo de que el paciente abandone la cita**. *Adicionalmente, el resto de variables mostró correlaciones bajas (|r| < 0.35), aportando dimensiones ortogonales e independientes para el clustering."*

DIAPOSITIVA 06 Criterio 3: Calidad de Datos (Nulos y Control de Outliers) — Steven

EN PANTALLA
Gráfico horizontal de nulos (`limpieza_nulos_antes.png`) y boxplots comparativos Antes vs. Después.

TIEMPO ASIGNADO
1:15 min | Tono: Riguroso en decisiones de calidad estadística.

GUION VERBAL DE STEVEN:

"En la fase de calidad y limpieza garantizamos integridad completa: el dataset no presentó nulos estructurales, conservando la totalidad de los **97,546 pacientes** *sin pérdida de registros. Respecto a los valores atípicos en gasto y frecuencia, tomamos una decisión fundamentada en el negocio:* **no eliminamos filas**, *ya que representan pacientes oncológicos o cardiovasculares reales de alta complejidad. En su lugar, aplicamos una* **Winsorización por Capping IQR** *en los umbrales de Tukey. Como evidencian los boxplots comparativos de 'Antes vs. Después', esto estabilizó las colas extremas sin sesgar la realidad clínica."*

Frase de Pase de Steven: "Para continuar, **le paso la palabra a mi siguiente compañero**."

DIAPOSITIVA 07 Criterio 3: Preprocesamiento: Estandarización con StandardScaler — Daniel

EN PANTALLA
Gráfico de densidades post-escalamiento (`escalamiento_distribuciones.png`) y ecuación Z-score.

TIEMPO ASIGNADO
1:00 min | Tono: Matemático y explicativo.

🎙️ **GUION VERBAL (DANIEL SE PRESENTA AL INICIO):**

"Buenas noches a todos, **mi nombre es Daniel**. *Dado que nuestras 10 variables operan en escalas heterogéneas —por ejemplo, el gasto en cientos de soles frente a ratios entre 0 y 1—, el escalamiento era indispensable. De omitirlo, el cálculo de distancias euclidianas en K-Means habría sido dominado arbitrariamente por las magnitudes monetarias. Aplicamos la transformación* **StandardScaler**, *llevando cada variable a* **media cero y varianza unitaria (Z-score)**. *La gráfica de distribuciones post-escalamiento corrobora que todas las dimensiones ingresan al modelo con paridad matemática e idéntico peso geométrico."*

DIAPOSITIVA 08 Criterio 4: Modelado No Supervisado: Determinación del K Óptimo — Daniel

EN PANTALLA
Gráficos de Inercia y Silueta (`clustering_metodo_codo_silueta.png`) + Dendrograma Ward.

TIEMPO ASIGNADO
1:30 min | Tono: Sólido, defendiendo la convergencia de las 3 métricas.

🎙️ **GUION VERBAL DE DANIEL:**

"Para determinar el hiperparámetro K no asumimos valores arbitrarios; realizamos una **triangulación cuantitativa entre tres métodos**: *en primer lugar, el* **Método del Codo** *muestra un punto de inflexión pronunciado en la inercia intra-clúster (WCSS) exactamente en* **K = 4**. *En segundo lugar, la curva del* **Coeficiente de Silueta** *valida esta partición al maximizar la cohesión y separación inter-grupo. En tercer lugar, el* **Dendrograma de Clustering Jerárquico** *con enlace de Ward confirma que la línea de corte horizontal a mayor distancia separa a la población de forma natural en* **cuatro ramas maestras**, *ratificando K = 4 con absoluta consistencia."*

🗣️ **Frase de Pase de Daniel:** "Ahora, **le paso la palabra a mi siguiente compañera**."

DIAPOSITIVA 09 Criterio 4: Proyección 2D con PCA y Separabilidad Espacial

Rosa

EN PANTALLA
Dispersión 2D con PCA (`clustering_segmentacion_pca_2d.png`), centroides con 'X' roja y varianza.

TIEMPO ASIGNADO
1:15 min | Tono: Visual y seguro.

GUION VERBAL (ROSA SE PRESENTA AL INICIO):

"Buenas noches con todos, **mi nombre es Rosa**. *Para validar y visualizar la geometría de los grupos redujimos las 10 dimensiones a dos componentes principales mediante* **PCA**. *El* **Componente Principal 1** *condensa el* **Eje de Complejidad y Gasto Clínico** *(citas acumuladas, gasto y diversidad médica), mientras que el* **Componente Principal 2** *refleja el* **Eje de Cumplimiento vs. Ausentismo** *(asistencia efectiva frente a demoras). Como se aprecia en la gráfica, los 4 grupos presentan una delimitación espacial nítida y los centroides marcados con la 'X' roja demuestran que el algoritmo convergió en particiones equilibradas y bien diferenciadas."*

DIAPOSITIVA 10 Criterio 4: Arquetipos de Pacientes y Estrategia Hospitalaria

Rosa

EN PANTALLA
Tabla de perfiles (`clustering_tabla_perfilamiento.png`) y tarjetas con las 4 estrategias.

TIEMPO ASIGNADO
1:45 min | Tono: Estratégico, orientado a la toma de decisiones.

GUION VERBAL DE ROSA:

"El valor principal de la analítica es orientar la toma de decisiones. A partir de los centroides caracterizamos **cuatro arquetipos de pacientes**:

- **Clúster 0 - Crónicos de Alta Complejidad:** *Adultos mayores con más de 10 citas anuales y alto gasto. Propuesta: paquetizar citas el mismo día y asignarles un gestor de caso clínico.*
- **Clúster 1 - Preventivos y Esporádicos Cumplidos:** *Consultas puntuales con asistencia superior al 90%. Propuesta: gestión ágil en canales de autoservicio.*
- **Clúster 2 - Críticos en Riesgo de Ausentismo (No-Show):** *Pacientes con esperas mayores a 25 días y muy baja asistencia.* **Es nuestro grupo prioritario:** *proponemos recordatorios automáticos por WhatsApp y sobre-asignación controlada (overbooking) para que los consultorios nunca queden vacíos.*
- **Clúster 3 - Nativos Digitales:** *Jóvenes con alta adopción de teleconsulta. Propuesta: incentivarlos hacia la atención virtual para descongestionar la infraestructura física."*

Frase de Pase de Rosa: "Para concluir con la presentación, **le paso la palabra a mi siguiente compañera**."

DIAPOSITIVA 11 Conclusiones del Avance 1 e Impacto Futuro (Hacia el Avance 2)

Brillite

EN PANTALLA
3 Conclusiones principales del Avance 1 y el diagrama hacia el Avance 2 (Modelos Supervisados).

TIEMPO ASIGNADO
1:15 min | Tono: Concluyente y visionario.

🎙️ **GUION VERBAL (BRILLITE SE PRESENTA AL INICIO):**

"Buenas noches, profesor y jurado, **mi nombre es Brillite**. *En conclusión de este Avance 1: primero, demostramos empíricamente que la población del Hospital María Auxiliadora no es homogénea y responde a cuatro perfiles operativamente diferenciables. Segundo, confirmamos que el tiempo de espera prolongado es la causa raíz del ausentismo. Estos resultados sientan las bases directas para el* **Avance 2***: utilizaremos la etiqueta del clúster obtenida hoy como una variable predictiva clave para entrenar clasificadores supervisados como* **Random Forest y XGBoost**. *Así construiremos un* **Sistema de Alerta Temprana** *que prediga en tiempo real la probabilidad de inasistencia antes de que la cita médica se pierda."*

DIAPOSITIVA 12 Cierre Institucional y Sesión de Preguntas

Brillite

EN PANTALLA
Mensaje de agradecimiento, firmas de los 6 integrantes y logotipo del curso.

TIEMPO ASIGNADO
0:30 min | Tono: Agradecido, profesional y cordial.

🎙️ **GUION VERBAL DE BRILLITE:**

"Agradecemos su atención y el espacio brindado por la cátedra para exponer este trabajo analítico. En nombre de todo nuestro equipo de trabajo, quedamos a su entera disposición para responder a las preguntas y recomendaciones del profesor y del jurado evaluador. ¡Muchas gracias!"

💡 **ESTRATEGIA PARA LA RONDA DE PREGUNTAS DEL EQUIPO:**

Si el docente hace preguntas técnicas, el integrante que expuso ese criterio debe tomar la iniciativa de responder para evidenciar dominio grupal equitativo.